

Regressione Lineare

L'analogia delle molle — lezione passo passo

Livello: Liceo Scienze Applicate (5° anno)

Cosa imparerai

1. Cos'è la **loss dei minimi quadrati** e perché si minimizza il quadrato degli scarti
2. L'analogia fisica: ogni punto è collegato alla retta con una **molla**
3. Come ricavare m e q con condizioni di **equilibrio** (forze e momenti)
4. La formula pratica in **forma centrata**
5. La dimostrazione che la soluzione trovata è il **minimo globale**

1. Il problema


Nella scienza e nella vita quotidiana ci troviamo spesso con un insieme di dati sperimentali e vogliamo capire se c'è una relazione lineare tra due grandezze. Ad esempio: più ore studio, più alto sarà il voto? Più corrente applico, più alta sarà la tensione?

La **regressione lineare** è il metodo che ci permette di trovare la retta che meglio descrive questa relazione.

Dati N punti sperimentali (x_i, y_i) , vogliamo trovare la retta

$$\hat{y} = mx + q \quad (1)$$

che «si adatta meglio» ai dati.



1.1. Un fenomeno fondamentale: i dati come realizzazioni di una gaussiana

Prima ancora di decidere **come** misurare la bontà di una retta, è importante capire **che tipo di fenomeno** stiamo osservando. Infatti i punti raccolti in un esperimento non cadono mai esattamente su una retta — né su nessun'altra curva «perfetta»: sono sempre un po' dispersi attorno al valore vero. Perché?

Quando in laboratorio misuriamo una grandezza, otteniamo ogni volta un valore leggermente diverso, anche ripetendo esattamente la stessa misura nelle stesse condizioni. Questa dispersione **non è un errore dello sperimentatore**: è una caratteristica intrinseca della misura, dovuta a molti piccoli disturbi — vibrazioni dell'ambiente, fluttuazioni termiche, precisione finita dello strumento, errori di lettura dell'occhio, rumore elettronico — ognuno dei quali sposta la lettura di una piccolissima quantità, casualmente in positivo o in negativo.

Esempio concreto — legge di Ohm. Prendiamo un resistore e facciamo passare una corrente $I = 0.3$ A, sempre la stessa; misuriamo la tensione V ai suoi capi. Ripetiamo la misura dieci volte, senza cambiare nulla. Otteniamo, per esempio:

$$6.08, \quad 6.12, \quad 6.05, \quad 6.15, \quad 6.09, \quad 6.11, \quad 6.07, \quad 6.13, \quad 6.10, \quad 6.08 \text{ V} \quad (2)$$

Il valore «vero» previsto dalla legge di Ohm (con $R = 20 \Omega$) sarebbe esattamente $V = RI = 6.00$ V. Le nostre misure, invece, si distribuiscono **attorno** a questo valore con una piccola dispersione: alcune un po' più alte, alcune un po' più basse, la maggior parte vicinissime al centro. Se mettessimo queste dieci misure su un istogramma, vedremmo emergere una forma a **campana**: simmetrica, concentrata vicino al valore vero, sempre più rara man mano che ci si allontana.

Questa campana ha un nome preciso: si chiama **distribuzione gaussiana** (o «normale»). È caratterizzata da due soli numeri: il **centro** della campana, che coincide con il valore «vero», e la sua **larghezza**, indicata con la lettera σ e chiamata **deviazione standard**. Valori di σ piccoli corrispondono a misure molto precise — tutte schiacciate vicino al centro; valori di σ grandi corrispondono a misure rumorose e sparpagliate. La formula esplicita di questa curva la vedremo più avanti, quando ci servirà per scegliere i parametri della retta.

Perché proprio una gaussiana? Non è una coincidenza: è la conseguenza di un risultato profondo della matematica, il **teorema del limite centrale**. Esso afferma che quando una grandezza è la **somma di tantissimi piccoli contributi casuali indipendenti**, la sua distribuzione tende sempre ad assomigliare a una gaussiana — qualunque sia la forma dei singoli contributi. Poiché l'errore di misura è proprio questo (la somma di molti micro-disturbi indipendenti), il risultato è sempre, approssimativamente, una gaussiana. Per questo la distribuzione normale compare ovunque: nel rumore di laboratorio, nell'altezza delle persone, nei punteggi di un test, nel rumore di un'immagine digitale.


1.1.1. Il modello dei dati

Torniamo al nostro problema. Quando raccogliamo N coppie (x_i, y_i) , **non** stiamo osservando punti perfetti su una retta: per ogni x_i il valore «vero» sarebbe $\hat{y}_i = mx_i + q$, ma ciò che effettivamente misuriamo è

$$y_i = \underbrace{mx_i + q}_{\text{valore vero } \hat{y}_i} + \underbrace{\varepsilon_i}_{\text{rumore di misura}} \quad (3)$$

dove ε_i è un'**estrazione casuale** da una gaussiana di media 0 e deviazione standard σ . In altre parole: **ogni dato y_i è la realizzazione di una variabile aleatoria gaussiana centrata sul valore vero $\hat{y}_i$.**

Visivamente dobbiamo quindi immaginare, al posto di una retta con cinque punti sopra, una retta con **una piccola gaussiana verticale appoggiata sopra ogni x_i** : ciascun punto osservato è stato «estratto» casualmente da quella gaussiana.



Ogni campana viola rappresenta la **distribuzione di probabilità** dei possibili valori che potremmo ottenere ripetendo la misura in quel punto: il massimo della campana sta sulla retta (il valore vero è il più probabile), e allontanandosi verso l'alto o verso il basso la probabilità diminuisce. Il punto verde è il valore che — in questa particolare realizzazione dell'esperimento — è stato effettivamente «pescato» dalla gaussiana.

Questa immagine ci dice molto di più del grafico iniziale: il problema di «trovare la retta migliore» significa in realtà **trovare i parametri m, q che collocano meglio le gaussiane del modello attorno ai dati osservati**. Nella sezione sull'interpretazione probabilistica vedremo che questa intuizione porta in modo naturale e inevitabile alla scelta dei **minimi quadrati**.

Domanda chiave: Cosa significa esattamente «si adatta meglio»? Dobbiamo definire una misura della distanza complessiva tra la retta e i punti. La risposta: minimizzare la somma dei quadrati dei residui r_i .

2. Loss (minimi quadrati)

Per ogni punto, lo **scarto verticale** (residuo) è la differenza tra il valore osservato y_i e il valore predetto dalla retta $\hat{y}_i$:

$$r_i = y_i - \hat{y}_i = y_i - (mx_i + q) \quad (4)$$

La **loss dei minimi quadrati** è la somma dei quadrati di tutti i residui:

$$S(m, q) = \sum_{i=1}^N r_i^2 = \sum_{i=1}^N (y_i - (mx_i + q))^2 \quad (5)$$

Trovare la migliore retta significa trovare m, q che **minimizzano** S .

3. Analogia fisica: molle, forze, energia

Immagina che ogni punto sia collegato alla retta con una **molla verticale**. La retta è libera di traslare su/giù (cambiando q) e di ruotare (cambiando m).

3.1. Legge di Hooke

L'**allungamento** della molla i -esima è il residuo r_i . La **forza** esercitata dalla molla (legge di Hooke):

$$F_i = kr_i \quad (6)$$

L'**energia potenziale elastica** accumulata dalla molla:

$$U_i = \frac{1}{2}kr_i^2 \quad (7)$$

3.2. Energia totale del sistema

$$U(m, q) = \sum_{i=1}^N U_i = \frac{k}{2} \sum_{i=1}^N r_i^2 \quad (8)$$

Poiché

$$U(m, q) = \frac{k}{2} S(m, q) \quad (9)$$

con $\frac{k}{2}$ costante positiva, vale:

$$\text{minimizzare } U \leftrightarrow \text{minimizzare } S$$

4. Condizioni di equilibrio

La retta può:

- **traslare** su/giù (cambia q)
- **ruotare** (cambia m)

In **equilibrio** non deve esserci né traslazione né rotazione.

4.1. Traslazione: somma delle forze = 0

$$\sum_{i=1}^N F_i = 0 \Rightarrow \sum k r_i = 0 \Rightarrow \quad (10)$$

$$\sum_{i=1}^N r_i = 0 \quad (11)$$

cioè:

$$\sum_{i=1}^N (y_i - m x_i - q) = 0 \quad (12)$$

4.2. Rotazione: somma dei momenti = 0

Il momento della forza F_i rispetto all'origine è $x_i F_i$. Quindi:

$$\sum_{i=1}^N x_i F_i = 0 \Rightarrow \sum x_i k r_i = 0 \Rightarrow \quad (13)$$

$$\sum_{i=1}^N x_i r_i = 0 \quad (14)$$

cioè:

$$\sum_{i=1}^N x_i (y_i - m x_i - q) = 0 \quad (15)$$

5. Identità utili

5.1. Medie

Definiamo le **medie**:

$$\bar{x} = \frac{1}{N} \sum x_i, \quad \bar{y} = \frac{1}{N} \sum y_i \quad (16)$$

5.2. Variabili centrate

$$X_i = x_i - \bar{x}, \quad Y_i = y_i - \bar{y} \quad (17)$$

Per costruzione, la somma degli scarti è sempre zero:

$$\sum X_i = 0, \quad \sum Y_i = 0 \quad (18)$$

5.3. Ricavare q dalla condizione $\sum r_i = 0$

Dalla condizione di traslazione $\sum r_i = 0$, dividendo per N , si ottiene subito:

$$q = \bar{y} - m\bar{x} \quad (19)$$

5.4. Osservazione: la retta passa per $(\bar{x}, \bar{y})$

Calcoliamo il valore predetto dalla retta nel punto $x = \bar{x}$:

$$\hat{y}(\bar{x}) = m\bar{x} + q = m\bar{x} + (\bar{y} - m\bar{x}) = \bar{y} \quad (20)$$

Proprietà: La retta dei minimi quadrati passa **sempre** per il punto $(\bar{x}, \bar{y})$, cioè per il «baricentro» dei dati. Questo è una conseguenza diretta della condizione di equilibrio $\sum r_i = 0$.

5.5. Anticipazione: la soluzione

Le sezioni successive dimostrano che le condizioni di equilibrio portano a queste formule. Definiamo i vettori degli scarti $\mathbf{X} = (X_1, \dots, X_N)$ e $\mathbf{Y} = (Y_1, \dots, Y_N)$:

$$m = \frac{\mathbf{X} \cdot \mathbf{Y}}{\mathbf{X} \cdot \mathbf{X}} \quad q = \bar{y} - m\bar{x} \quad (21)$$

dove $\mathbf{X} \cdot \mathbf{Y} = \sum X_i Y_i$ e $\mathbf{X} \cdot \mathbf{X} = \sum X_i^2$ sono **prodotti scalari**.

5.6. Residui in forma centrata

Se $q = \bar{y} - m\bar{x}$, i residui diventano:

$$r_i = y_i - (mx_i + q) = (y_i - \bar{y}) - m(x_i - \bar{x}) \quad (22)$$

$$r_i = Y_i - mX_i \quad (23)$$

6. Ricavare m e q in forma centrata

Usiamo la condizione di rotazione e la rendiamo «centrata».

6.1. Da $\sum x_i r_i = 0$ a $\sum X_i r_i = 0$

Poiché $x_i = X_i + \bar{x}$:

$$\sum x_i r_i = \sum (X_i + \bar{x}) r_i = \sum X_i r_i + \bar{x} \sum r_i \quad (24)$$

Ma in equilibrio $\sum r_i = 0$, quindi:

$$\sum x_i r_i = 0 \leftrightarrow \sum X_i r_i = 0 \quad (25)$$

6.2. Sostituisco $r_i = Y_i - mX_i$

$$\sum X_i r_i = 0 \Rightarrow \sum X_i (Y_i - mX_i) = 0 \quad (26)$$

$$\sum X_i Y_i - m \sum X_i^2 = 0 \quad (27)$$

$$m = \frac{\sum X_i Y_i}{\sum X_i^2} \quad (28)$$

Esplicitando:

$$m = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad (29)$$

$$q = \bar{y} - m\bar{x} \quad (30)$$

7. Dimostrazione: una retta diversa ha energia maggiore (minimo globale)

7.1. Impostazione

Sia (m^*, q^*) la retta che soddisfa le condizioni di equilibrio, con residui:

$$r_i^* = y_i - (m^* x_i + q^*) \quad (31)$$

Allora, per le condizioni di equilibrio:

$$\sum r_i^* = 0, \quad \sum x_i r_i^* = 0 \quad (32)$$

7.2. Retta perturbata

Prendiamo una retta **qualsunque**:

$$m = m^* + \varepsilon, \quad q = q^* + \delta \quad (33)$$

I nuovi residui sono:

$$r_i = y_i - ((m^* + \varepsilon)x_i + (q^* + \delta)) = r_i^* - \varepsilon x_i - \delta \quad (34)$$

7.3. Confronto delle loss

$$S(m, q) - S(m^*, q^*) = \sum (r_i^* - \varepsilon x_i - \delta)^2 - \sum (r_i^*)^2 \quad (35)$$

Sviluppando:

$$= \sum (\varepsilon x_i + \delta)^2 - 2\varepsilon \sum x_i r_i^* - 2\delta \sum r_i^* \quad (36)$$

Usando l'equilibrio ($\sum r_i^* = 0$ e $\sum x_i r_i^* = 0$):

$$S(m, q) - S^* = \sum (\varepsilon x_i + \delta)^2 \geq 0 \quad (37)$$

dove $S^* = S(m^*, q^*)$.

7.4. Conclusione

$$S(m, q) \geq S^* \Rightarrow U(m, q) \geq U(m^*, q^*)$$

La retta trovata è un **minimo globale** dell'energia (e della loss).

8. Interpretazione probabilistica: perché proprio il quadrato?

Finora abbiamo scelto come «misura dell'errore» la somma dei **quadrati** degli scarti. Ma perché proprio il quadrato, e non — per esempio — il modulo $|r_i|$? La risposta profonda non è geometrica ma **probabilistica**.

8.1. Il rumore nelle misure

In ogni esperimento reale le misure sono affette da **rumore**: piccoli errori di lettura, vibrazioni, limiti degli strumenti, fluttuazioni ambientali. Il modello realistico non è quindi « y_i sta esattamente sulla retta» ma:


$$y_i = \underbrace{mx_i + q}_{\text{valore vero } \hat{y}_i} + \underbrace{\varepsilon_i}_{\text{rumore casuale}} \quad (38)$$

dove ε_i è un errore casuale, diverso per ogni misura. In moltissime situazioni fisiche — per il **teorema del limite centrale** — questo errore segue una **distribuzione gaussiana** (o «normale») di media 0 e deviazione standard σ :

$$p(\varepsilon) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right) \quad (39)$$

Interpretazione: se la retta «vera» fosse $\hat{y}_i = mx_i + q$, ogni osservazione y_i sarebbe **estratta a caso** da una gaussiana centrata in $\hat{y}_i$, larga σ . Il dataset è dunque un **campione di N gaussiane**, una per ogni x_i .

8.2. Una gaussiana verticale per ogni punto



Ogni curva viola rappresenta la **densità di probabilità** dei valori di y che possiamo osservare per la x_i corrispondente: più ci si avvicina al centro (sulla retta blu), più l'osservazione è probabile; lontano dal centro la probabilità cala rapidamente. Il punto verde è il valore che è **effettivamente stato estratto** da quella gaussiana.

8.3. Perché il quadrato: massima verosimiglianza

La probabilità (densità) che il modello con parametri m, q produca proprio il valore osservato y_i è il valore della gaussiana calcolata in y_i :

$$p(y_i | m, q) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}\right) \quad (40)$$

Se le N misure sono **indipendenti**, la probabilità di osservare l'intero **dataset** è il prodotto delle singole probabilità. Questa quantità si chiama **verosimiglianza** (likelihood) e la indichiamo con L :

$$L(m, q) = \prod_{i=1}^N p(y_i | m, q) = \frac{1}{(\sigma\sqrt{2\pi})^N} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \hat{y}_i)^2\right) \quad (41)$$

Idea chiave: scegliamo i parametri m, q che rendono **massima** L , cioè quelli per cui «i dati osservati erano i più probabili». Questo principio si chiama **massima verosimiglianza** (Maximum Likelihood Estimation, MLE).

Per lavorare col prodotto applichiamo il logaritmo. Poiché log è monotono crescente, massimizzare L è equivalente a massimizzare $\log L$:

$$\log L(m, q) = \text{cost.} - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (42)$$

Il primo termine non dipende da m, q . Il secondo ha un **segno meno** davanti alla somma dei quadrati: massimizzarlo equivale a **minimizzare** quella somma.

massimizzare la verosimiglianza $\Leftrightarrow$ minimizzare $\sum r_i^2$

Risposta alla domanda iniziale: se il rumore è gaussiano, minimizzare la somma dei quadrati è la scelta **probabilisticamente ottimale**. I parametri (m, q) trovati con i minimi quadrati sono quelli che rendono **massima la probabilità di osservare proprio quei dati**.

8.4. E se usassimo il modulo $|r_i|$?

Avremmo potuto scegliere come misura di errore la somma dei **valori assoluti** $\sum |r_i|$. È una scelta lecita, ma corrisponde ad assumere che il rumore segua una **distribuzione di Laplace** (a doppio esponenziale), non gaussiana. Inoltre $|r_i|$ non è derivabile in 0, e rende il problema matematicamente meno trattabile.

Per la maggior parte dei fenomeni fisici il rumore è invece **gaussiano** (teorema del limite centrale: quando un errore è somma di molti piccoli contributi indipendenti, la sua distribuzione tende alla gaussiana). Ecco perché i minimi quadrati sono la scelta «naturale» e universalmente adottata.

9. Regressione lineare come problema di machine learning

Quello che abbiamo appena fatto — partire da dati, trovare parametri ottimali, usare il modello per fare previsioni — è **esattamente** la struttura di un qualsiasi problema di **machine learning** (apprendimento automatico).

9.1. Lo schema generale: dati → parametri → predizioni

- | | |
|------------------------------------|---|
| 1. Dati | Un insieme di esempi (x_i, y_i) . Nella nostra regressione: coppie di numeri. Nel ML reale: immagini etichettate, frasi tradotte, registrazioni audio, partite a scacchi, ... |
| 2. Modello | Una famiglia di funzioni $\hat{y} = f(x; \theta)$ dipendenti da parametri θ . Qui $\theta = (m, q)$: solo due numeri. |
| 3. Loss | Una funzione $S(\theta)$ che misura quanto il modello sbaglia sui dati. Qui: $S(m, q) = \sum r_i^2$. Come abbiamo visto, dietro questa scelta c'è la massima verosimiglianza. |
| 4. Addestramento (training) | Trovare i parametri θ^* che minimizzano la loss. Qui: formule chiuse (la soluzione $m = \frac{X \cdot Y}{X \cdot X}$). Nel ML moderno: discesa del gradiente , milioni di piccoli passi iterativi. |
| 5. Inferenza (inference) | Dato un nuovo x mai visto prima, predire $\hat{y} = f(x; \theta^*)$. Qui: calcolare $m^*x + q^*$. Nel ML: classificare un'immagine, generare testo, riconoscere una voce, ... |

9.2. L'essenza: comprimere i dati nei parametri

Il punto chiave del machine learning è **riassumere** l'informazione contenuta in tanti dati dentro un **numero ridotto di parametri**. Nel nostro esempio abbiamo «compresso» 5 punti (cioè 10 numeri) in 2 soli parametri m, q : il modello è molto più piccolo dei dati, eppure permette di fare previsioni.

Una rete neurale fa la stessa cosa ma su scala enormemente diversa: GPT-4 ha circa **mille miliardi di parametri**, addestrato su una frazione importante del web. Ma l'idea di fondo è invariata:

dati → parametri → predizioni

9.3. Cosa cambia in una rete neurale?

Rispetto alla nostra regressione, in un modello moderno cambiano tre cose principali:

Modello più ricco

Non una retta con 2 parametri, ma una rete con **milioni o miliardi** di parametri, capace di rappresentare funzioni molto complesse (non lineari).

Loss diversa

Tipicamente la **cross-entropy** per i problemi di classificazione, invece dei minimi quadrati. Il principio (massima verosimiglianza) resta lo stesso.

Addestramento iterativo

Niente formula chiusa: si usa la **discesa del gradiente**, milioni di piccoli aggiustamenti ai parametri guidati dalle derivate della loss.

Ma la struttura concettuale — **dati + modello + loss** → **addestramento** → **inferenza** — resta **identica** dalla regressione lineare a GPT.

In sintesi. Avete appena risolto a mano, con carta e penna, un problema di **machine learning** nella sua forma più elementare, capendo anche la **ragione probabilistica** dietro la scelta della loss. Non a caso la regressione lineare viene chiamata il «Hello World» del ML: abbastanza semplice da farsi senza computer, abbastanza profonda da contenere tutti i concetti chiave (dati, modello, loss, addestramento, inferenza, massima verosimiglianza).

10. Riepilogo

Con $\mathbf{X} = (X_1, \dots, X_N)$ e $\mathbf{Y} = (Y_1, \dots, Y_N)$ vettori degli scarti dalle medie:

Problema Trovare la retta $\hat{y} = mx + q$ più vicina a N punti

Loss $S(m, q) = \sum (y_i - mx_i - q)^2$

Analogia Molle verticali $\rightarrow U = \frac{k}{2}S \rightarrow$ minimizzare $S =$ equilibrio

Equilibrio Somma forze = 0 + Somma momenti = 0

Soluzione $m = \frac{\mathbf{X} \cdot \mathbf{Y}}{\mathbf{X} \cdot \mathbf{X}}, \quad q = \bar{y} - m\bar{x}$

Baricentro La retta passa sempre per $(\bar{x}, \bar{y})$

Minimo globale $S(m, q) - S^* = \sum (\varepsilon x_i + \delta)^2 \geq 0$ per qualsiasi altra retta

11. Tabella modello per i calcoli

Questa tabella permette di calcolare m e q in modo sistematico.

11.0.1. Step 0 — Calcola le medie

$$\bar{x} = \frac{\sum x_i}{N}, \quad \bar{y} = \frac{\sum y_i}{N} \tag{43}$$

11.0.2. Step 1 — Compila la tabella

i	x_i	y_i	$X_i = x_i - \bar{x}$	$Y_i = y_i - \bar{y}$	X_i^2	$X_i Y_i$
1						
2						
3						
4						
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
Somme	$\sum x_i$	$\sum y_i$	0	0	$\sum X_i^2$	$\sum X_i Y_i$

Tabella 1: Tabella modello — forma centrata. Le colonne $\sum X_i$ e $\sum Y_i$ devono dare 0 (controllo).

11.0.3. Step 2 — Calcola m e q

$$m = \frac{\sum X_i Y_i}{\sum X_i^2} = \frac{\mathbf{X} \cdot \mathbf{Y}}{\mathbf{X} \cdot \mathbf{X}} \quad q = \bar{y} - m\bar{x} \tag{44}$$

12. Esempio numerico svolto

Dati 5 punti: (1, 3), (2, 5), (3, 4), (4, 6), (5, 7).

12.0.1. Step 0 — Medie

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5}{5} = 3 \qquad \bar{y} = \frac{3 + 5 + 4 + 6 + 7}{5} = 5 \tag{45}$$

12.0.2. Step 1 — Tabella

<i>i</i>	<i>x_i</i>	<i>y_i</i>	<i>X_i</i>	<i>Y_i</i>	<i>X_i²</i>	<i>X_iY_i</i>
1	1	3	−2	−2	4	4
2	2	5	−1	0	1	0
3	3	4	0	−1	0	0
4	4	6	1	1	1	1
5	5	7	2	2	4	4
Somme	15	25	0 ✓	0 ✓	10	9

Tabella 2: Esempio numerico svolto

12.0.3. Step 2 — Risultati

$$m = \frac{X \cdot Y}{X \cdot X} = \frac{9}{10} = 0.9 \tag{46}$$

$$q = \bar{y} - m\bar{x} = 5 - 0.9 \times 3 = 5 - 2.7 = 2.3 \tag{47}$$

$$\hat{y} = 0.9x + 2.3$$

13. Esercizio svolto: legge di Ohm

Contesto: In laboratorio applichi diverse tensioni V a un resistore e misuri la corrente I . Per la legge di Ohm, $V = RI$, quindi ti aspetti una relazione lineare tra I (asse x) e V (asse y), con pendenza $m = R$ e intercetta $q \approx 0$.

Dati raccolti ($N = 6$):

i	1	2	3	4	5	6
I_i (A)	0.1	0.2	0.3	0.4	0.5	0.6
V_i (V)	2.2	3.9	6.1	8.0	9.8	12.1

13.0.1. Step 0 — Medie

$$\bar{x} = \frac{0.1 + 0.2 + 0.3 + 0.4 + 0.5 + 0.6}{6} = \frac{2.1}{6} = 0.35 \tag{48}$$

$$\bar{y} = \frac{2.2 + 3.9 + 6.1 + 8.0 + 9.8 + 12.1}{6} = \frac{42.1}{6} \approx 7.017 \tag{49}$$

13.0.2. Step 1 — Tabella

i	x_i	y_i	X_i	Y_i	X_i^2	$X_i Y_i$
1	0.1	2.2	-0.25	-4.817	0.0625	1.204
2	0.2	3.9	-0.15	-3.117	0.0225	0.468
3	0.3	6.1	-0.05	-0.917	0.0025	0.046
4	0.4	8.0	0.05	0.983	0.0025	0.049
5	0.5	9.8	0.15	2.783	0.0225	0.417
6	0.6	12.1	0.25	5.083	0.0625	1.271
Somme	2.1	42.1	0 ✓	0 ✓	0.175	3.455

Tabella 4: I valori sono arrotondati a 3 cifre decimali.

,)

13.0.3. Step 2 — Risultati

$$m = \frac{3.455}{0.175} \approx 19.74 \quad q = 7.017 - 19.74 \times 0.35 \approx 0.11 \tag{50}$$

$$\hat{V} = 19.74I + 0.11$$

Interpretazione: la resistenza è $R \approx 19.7 \, \Omega$. L'intercetta $q \approx 0.1 \, \text{V}$ è quasi zero, coerente con la legge di Ohm ($V = RI$ passa per l'origine).

14. Esercizio svolto: prezzo di rivendita delle sneakers

Contesto: Vuoi capire come il numero di paia prodotte (edizione limitata) influenza il prezzo di rivendita di sneakers da collezione. Meno paia → più rare → prezzo più alto?

Dati raccolti da 6 modelli (x = migliaia di paia prodotte, y = prezzo di rivendita in euro):

i	1	2	3	4	5	6
Paia (migliaia)	2	5	8	12	20	30
Prezzo (€)	950	720	580	430	310	210

14.0.1. Step 0 — Medie

$$\bar{x} = \frac{2 + 5 + 8 + 12 + 20 + 30}{6} = \frac{77}{6} \approx 12.83 \quad (51)$$

$$\bar{y} = \frac{950 + 720 + 580 + 430 + 310 + 210}{6} = \frac{3200}{6} \approx 533.3 \quad (52)$$

14.0.2. Step 1 — Tabella

i	x_i	y_i	X_i	Y_i	X_i^2	$X_i Y_i$
1	2	950	-10.83	416.7	117.4	-4513.9
2	5	720	-7.83	186.7	61.4	-1462.2
3	8	580	-4.83	46.7	23.4	-225.6
4	12	430	-0.83	-103.3	0.7	86.1
5	20	310	7.17	-223.3	51.4	-1600.6
6	30	210	17.17	-323.3	294.7	-5550.6
Somme	77	3200	0 ✓	0 ✓	548.8	-13266.7

14.0.3. Step 2 — Risultati

$$m = \frac{-13266.7}{548.8} \approx -24.2 \quad q = 533.3 - (-24.2) \times 12.83 \approx 843.5 \quad (53)$$

$$\hat{y} = -24.2x + 844$$

Interpretazione: ogni 1000 paia in più prodotte, il prezzo di rivendita scende di circa 24 €. La pendenza **negativa** conferma: meno raro = meno costoso.

Predizione: per un modello con 15 000 paia: $\hat{y} = -24.2 \times 15 + 844 \approx 481$ €.

15. Esercizio svolto: ore di studio vs voto al compito

Contesto: Un professore raccoglie dati anonimi: quante ore hanno studiato gli studenti e che voto hanno preso al compito di matematica. C'è una relazione lineare?

Dati di 7 studenti (x = ore di studio, y = voto):

i	1	2	3	4	5	6	7
Ore	1	2	3	4	5	6	7
Voto	4	4.5	5	6	7	7.5	8

15.0.1. Step 0 — Medie

$$\bar{x} = \frac{1+2+3+4+5+6+7}{7} = \frac{28}{7} = 4 \quad \bar{y} = \frac{4+4.5+5+6+7+7.5+8}{7} = \frac{42}{7} = 6 \quad (54)$$

15.0.2. Step 1 — Tabella

i	x_i	y_i	X_i	Y_i	X_i^2	$X_i Y_i$
1	1	4	-3	-2	9	6
2	2	4.5	-2	-1.5	4	3
3	3	5	-1	-1	1	1
4	4	6	0	0	0	0
5	5	7	1	1	1	1
6	6	7.5	2	1.5	4	3
7	7	8	3	2	9	6
Somme	28	42	0 ✓	0 ✓	28	20

15.0.3. Step 2 — Risultati

$$m = \frac{20}{28} = \frac{5}{7} \approx 0.71 \quad q = 6 - \frac{5}{7} \times 4 = 6 - \frac{20}{7} = \frac{22}{7} \approx 3.14 \quad (55)$$

$$\hat{y} = 0.71x + 3.14$$

Interpretazione: ogni ora di studio in più, il voto aumenta di circa 0.7 punti. Uno studente che non studia ($x = 0$) si aspetta un voto ≈ 3.1 (insufficiente).

Predizione: con 8 ore di studio: $\hat{y} = 0.71 \times 8 + 3.14 \approx 8.8$.

16. Esercizi da svolgere

16.1. Esercizio 1

Trova la retta $\hat{y} = mx + q$ per i seguenti dati ($N = 5$):

i	1	2	3	4	5
x_i	2	4	6	8	10
y_i	5	9	11	16	19

(Risultati: $\bar{x} = 6$, $\bar{y} = 12$, $\sum X_i^2 = 40$, $\sum X_i Y_i = 70$, $m = 1.75$, $q = 1.5$)

16.2. Esercizio 2

Trova la retta $\hat{y} = mx + q$ per i seguenti dati ($N = 6$):

i	1	2	3	4	5	6
x_i	1	3	5	7	9	11
y_i	20	17	13	11	8	3

(Risultati: $\bar{x} = 6$, $\bar{y} = 12$, $\sum X_i^2 = 70$, $\sum X_i Y_i = -114$, $m \approx -1.63$, $q \approx 21.77$)

16.3. Esercizio 3

Trova la retta $\hat{y} = mx + q$ per i seguenti dati ($N = 4$):

i	1	2	3	4
x_i	10	20	30	40
y_i	22	38	51	69

(Risultati: $\bar{x} = 25$, $\bar{y} = 45$, $\sum X_i^2 = 500$, $\sum X_i Y_i = 770$, $m = 1.54$, $q = 6.5$)